

一个基于用户画像的商品推荐算法的设计与应用

吕超, 朱郑州

(北京大学软件与微电子学院, 北京 100871)

摘要: 以用户画像的商品推荐为研究背景, 在真实的电商环境下, 使用海量数据构建用户画像和商品画像。对画像数据进行详细探讨, 并针对不同的优化目标对训练目标中使用的标签数据进行区分和说明, 实现了一个线上栏目的商品推荐算法。详细阐明用户画像和商品画像的构建方案, 以说明关联用户和商品交互信息的标签数据的获取。定义分别以销量和点击率为优化目标, 并分别给出了这两种优化目标的不同标签构建方案和实现方法。在构建用户画像、商品画像和标签数据后, 详细说明特征构建的过程; 在构建特征数据和优化目标后, 详细阐明基于机器学习中梯度提升决策树的模型训练过程和参数调整方案得到的分数预测模型。最后利用训练好的分数预测模型、新用户列表和推荐的商品召回列表进行商品推荐。在完成商品推荐算法的设计和实现后, 对模型进行应用和验证。研究结果证实, 本文算法相比人工排序能获得更好的结果。

关键词: 计算机应用; 用户画像; 电子商务; 梯度提升决策树; 推荐算法

中图分类号: TP391 **文献标识码:** A **文章编号:** 1674-2850(2018)04-0339-09

Design and application of a commodity recommendation algorithm based on user portrait

LÜ Chao, ZHU Zhengzhou

(School of Software & Microelectronics, Peking University, Beijing 100871, China)

Abstract: Based on the user portrait of the commodity recommendation as the research background, in the real electricity supplier environment, massive data is used to build user portrait and commodity portrait. With detailed discussion on the portrait data, the used label data of the training target for different optimization goals are distinguished and described, then an online column recommendation algorithm is implemented. This paper expounds the construction scheme of the user portrait and commodity portrait, and then explains the acquisition of the tag data of the interactive user and commodity interactive information. This paper defines the optimization target of sales volume and click rate respectively, and gives the different label construction schemes and realization methods of these two optimization targets. After the construction of user portrait, commodity portrait and tag data, the process of characteristics construction is described in detail. After the construction of characteristics data and the optimization goal, the score prediction model is elaborated based on the model training process and parameter adjustment method of gradient boosted decision tree in machine learning. Finally, the training score prediction model, new user list and recommended commodity recall list are used for commodity recommendation in this paper. After completing the design and implementation of the commodity recommendation algorithm, the model is applied and verified. The results show that the algorithm in this paper can get better results than the manual sorting.

Key words: computer applications; user portrait; E-commerce; gradient boosted decision tree; recommendation algorithm

基金项目: 国家自然科学基金青年科学基金(61402020); 高等学校博士学科点专项科研基金(20130001120021)

作者简介: 吕超(1989—), 男, 硕士研究生, 主要研究方向: 大数据技术、个性化推荐

通信联系人: 朱郑州, 副教授, 主要研究方向: 教育大数据、项目管理文化与环境. E-mail: zzzmad@163.com

0 引言

在当今这个以海量数据、人工智能为主,技术快速发展、日新月异的时代,信息的爆炸和过载问题应运而生。这个信息过载的时代对于信息的需求者和创造者来说,都面临着很大的困难。对于信息的需求者,从海量的信息中抽取自己感兴趣的信息是一件极其苛求的事情。对于信息的创造者,使自己的信息在众多自媒体遍地开花的当今脱颖而出,得到众多信息需求者的关注,也是一件极困难的事情。推荐系统就是解决这一矛盾的重要工具。推荐算法的目标是关联用户和信息,一方面帮助信息需求者发现对自己有价值的信息,另一方面也让信息的创造者更快地找到更大的信息需求点,从而实现信息需求者和信息创造者的双赢。

推荐算法的主要应用场景有电子商务^[1](Amazon、eBay、京东商城、天猫、Hulu等)、信息检索^[2](如iGoogle、MyYahoo、GroupLens、百度等)、移动应用^[3](Daily Learner)、生活服务^[4]等领域。

本文的推荐介质是借助商家这个媒体来模拟向用户推荐的过程,开发出向有购物需求的用户推荐商品的一套算法。在这个领域,实现个性化推荐的途径主要是商家为用户提供全方位的数据,精准刻画用户的购买意图,在对客户全面了解的前提下,为用户推荐潜在的心仪商品。既能增强顾客的购物体验,也能为顾客节省挑选商品的时间,从而为商家增加下单转化率,也可增强商家的用户黏性。

本文研究内容是设计一个描述电商网站用户的用户画像,然后构建一个商品推荐算法并将其实现,并在实际的电商环境中运行算法。在获取一段时间用户的购买数据后,监测算法的推荐效果。

1 相关概念

1.1 用户画像的定义与特征

在大数据时代对用户和商品的准确刻画,无疑对于企业识别特定群体的客户和帮助客户准确识别特定商品都是必要的。电商企业了解消费者的购买习惯和特定消费者的群体特性对于精准化的商业推荐也十分有帮助^[5]。在传统市场中,准确、及时地了解消费者的喜好和购买行为习惯就像薛定谔的猫一样难以破解。而在当前互联网大数据的情境下,使电商领域中对用户的购买行为及顾客满意度的实时把控和精准推荐有了可能。用户画像又称用户角色(Persona),是对具有某一特性的特定人群的描述。用户画像帮助企业定位到目标客户并根据画像定位到市场需求,然后对用户画像符合的特定群体进行商业活动。在海量数据下进行自动化的数据采集和智能的数据抽取并形成用户画像,并标记不同客户的需求。自动化的用户画像采集极大提升了用户定位的精确度和对市场的反应速度。

商品推荐算法是基于用户画像和商品画像设计的。首先根据原始用户行为日志生成用户画像。网站建设初期会建立一整套用户行为收集机制,也就是日志系统。在较大规模的互联网公司中会话日志通常存储在分布式的数据仓库中,如支持离线分析的Hive数据仓库。互联网公司会从多种用户操作维度来收集用户行为日志,例如用户的每次浏览行为都会记录为一次浏览日志,而在电商公司中的每次购买行为则会记录存储为一条订单日志。

1.2 推荐算法

协同过滤算法在20世纪90年代被提出后,随着互联网的诞生,已经开始了以环节信息过载为目的,对推荐算法进行的深入研究。根据用户和项目间的相似性关系挖掘每个用户潜在感兴趣的项目,在帮助用户主体寻找感兴趣的客体的同时,也帮助客体更有效地出现在对其感兴趣的用户面前。ADOMAVICIUS等^[6]给出了推荐算法形式化的定义,如式(1)所示,其中, C 为用户集合, S 为推荐项目集合,通过计算项目 s_i 对用户 c_i 的相关程度来计算用户与项目的相关度。计算过程表示为 $u:C \times S \rightarrow R$,其中, u 为目标用

户； R 为排序后的项目集合。找到最终的项目列表为推荐算法的目标，使得函数 $u(\cdot)$ 取得最大值。 s'_i 为用户 c_i 取得最大函数值的项目，如式 (1) 所示。

$$\forall c_i \in C, s'_i = \arg \max_{s_i \in S} (c_i, s_i). \quad (1)$$

在信息检索领域首次提出排序学习时，已在该领域开展了大量的应用和实践研究。经典的链接分析就是信息检索领域的经典模型，还有布尔、向量空间、概率、语言模型等。这些模型的共同点是利用一些简单的特征进行词频，逆文档频率的简单特点是进行无监督排序。需要进行经验参数的调整才可以得到这些传统排序方法的最优参数，从而按照一定的标准排序检索文档。排序学习的诞生伴随着搜索引擎需要处理的数据呈指数增长。排序学习是利用机器学习中解决分类与回归方法来解决排序问题，其在文本检索中能够针对文本的相关性、重要性等衡量标准自动从训练数据中学习得到一个排序函数，从而对文本进行排序。

FUHR^[7]利用最小二乘回归进行排序学习。2000 年，微软亚洲研究院针对排序学习提出采用支持向量机构建排序模型 Ranking SVM^[7-8]、利用梯度下降算法训练神经网络的排序模型 RankNet^[9-10]、使用 boost 构建排序函数的方法 RankBoost^[11]。根据输入的排序对象不同，排序学习一般可分为三类^[1]：点级 (pointwise)、对级 (pairwise)、列表级 (listwise)。点级方法分为回归和分类两种，输入每个排序对象的特征；对级方法更接近排序问题的实质，这是因为排序时需考虑文档之间的先后顺序关系；列表级方法更加全面地考虑不同文档的序列关系是否关联了所有关联文档的集合。由于大规模排序的效率问题，本文采用点级排序学习策略。

点级排序学习的主要思想是，将排序问题转化为多分类问题或回归问题。系统从训练数据中学习得到分类或回归模型，之后通过对项目进行打分返回项目列表。点级排序思想的应用之一为隐语义模型 (latent factor model, LFM)。KOREN 等^[12]于 2009 年首次将 LFM 引入推荐系统，使用降维的矩阵因式分解法，通过隐含特征来填充用户和评分矩阵。将用户-项目评分矩阵分解为用户-隐含特征矩阵和物品-隐含特征矩阵，矩阵因式分解方法为 LFM 的一般应用方式，可以预测用户 u 对物品 i 的兴趣度评分 \hat{r}_{ui} ，如式 (2) 所示。

$$\hat{r}_{ui} = \sum_{k=1}^K p_{u,k} q_{i,k}, \quad (2)$$

其中， $p_{u,k}$ 为度量用户 u 的兴趣度与第 k 个隐类的关系， $k \in [1, K]$ ； $q_{i,k}$ 为度量物品 i 与第 k 个隐类的关系。接着，定义损失函数进行迭代优化，并加入正则化因子以避免过拟合现象，找到最合适的参数 p_u 和 q_i ，如式 (3) 所示。

$$\min_{p, q} \left(\sum_{(u,i) \in K} (r_{ui} - \hat{r}_{ui})^2 + \lambda \|p_u\|^2 + \lambda \|q_i\|^2 \right) = \min_{p, q} \left(\sum_{(u,i) \in (1, K)} \left(r_{ui} - \sum_{k=1}^K p_{u,k} q_{i,k} \right)^2 + \lambda \|p_u\|^2 + \lambda \|q_i\|^2 \right), \quad (3)$$

其中， r_{ui} 为用户 u 对物品 i 的实际评分； λ 为正则化参数。利用随机梯度下降法求得其全局最小值及损失函数。通过迭代法不断优化参数，最终得到最优的“用户-隐含特征”矩阵和“物品-隐含特征”矩阵。矩阵计算向量内积得到“用户-物品”评分矩阵。为得到物品评分，取前 N 个物品作为推荐结果推荐给目标用户。

2 用户画像构建

用户画像构建算法主要通过取得用户来自 3 个维度的商品描述词来构建画像，即分类词、产品词和

品牌关键词。基于过去两年内用户在商城的所有浏览和购买行为，可以计算出在每个用户行为的三级分类下，用户对哪些商品兴趣强度高于该分类所有用户的平均水平，将这些商品的标签作为用户的兴趣标签。在商品的3个特征维度基础上，从用户角度，再分为点击、购买、收藏和加购物车4个维度。用户画像构建算法流程如图1所示。

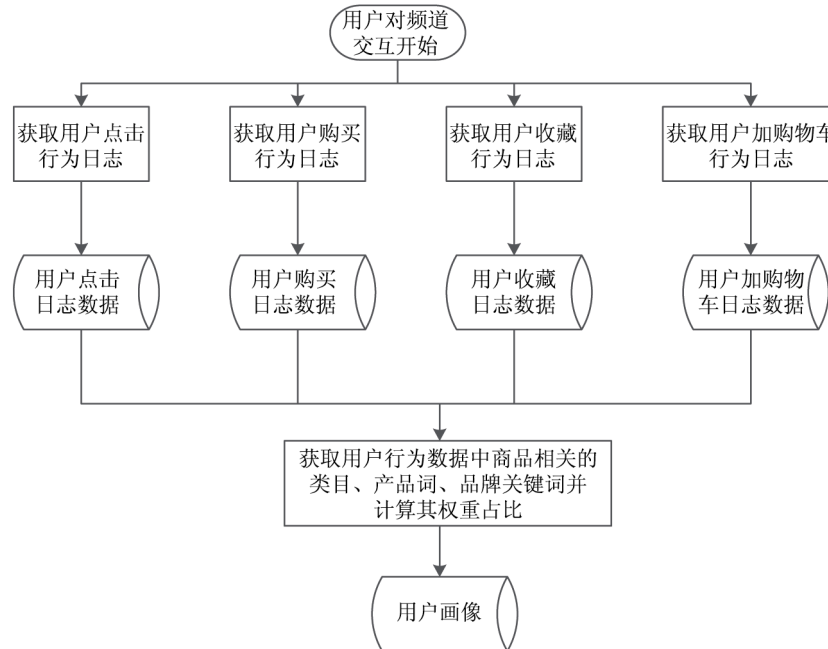


图1 用户画像构建流程

Fig. 1 Construction flow of user portrait

用户画像构建有4个用户操作维度的信息待收集和计算，具体如算法1所示。步骤1，需要为每个用户建立一个用户画像，并为其新建一个空的待填充画像。步骤2，根据用户编号和点击日志数据计算出用户点击维度的描述词的权重，并在计算过程中根据点击时间的衰减来描述词的相对权重和归一化。步骤3，根据用户编号和购买日志数据计算出用户购买维度的描述词权重。步骤4，根据用户编号和收藏日志数据计算出用户收藏维度的描述词权重。步骤5，根据用户编号和加购物车数据计算出用户加购物车维度的描述词权重。步骤6，构建用户画像完毕，返回用户画像结果。衰减描述词权重和归一化操作主要是因为一些用户的操作过于陈旧，应该给用户很久之前的操作较少的权重，而给新近的操作较高的权重，具体做法如算法2所示。

算法1：用户画像构建算法

输入： $U = \{u_1, u_2, \dots, u_n\}$, current_time,

Click = {click₁, click₂, ..., click_n}, click_i = < u_i, s_i, ct_i, cate_i, pword_i, brand_i > ,

Order = {order₁, order₂, ..., order_n}, order_i = < u_i, s_i, ot_i, cate_i, pword_i, brand_i > ,

Follow = {follow₁, follow₂, ..., follow_n}, follow_i = < u_i, s_i, ft_i, cate_i, pword_i, brand_i > ,

Cart = {cart₁, cart₂, ..., cart_n}, cart_i = < u_i, s_i, cartT_i, cate_i, pword_i, brand_i > ;

输出： UserProfile = {up₁, up₂, ..., up_n}, up_i = < u_i, Cate_i, Pword_i, Brand_i > ,

Cate_i = {cate_{i1} : cw_{i1}, cate_{i2} : cw_{i2}, ..., cate_{ia} : cw_{ia}} ,

Pword_i = {pword_{i1} : pw_{i1}, pword_{i2} : pw_{i2}, ..., pword_{ib} : pw_{ib}} ,

Brand_i = {brand_{i1} : bw_{i1}, brand_{i2} : bw_{i2}, ..., brand_{ic} : bw_{ic}} .

1. for u_i in U :
 - $up_i \leftarrow \{u_i, cate_i, pword_i, brand_i\}$,
 - $up_i.cate_i \leftarrow []$, $up_i.pword_i \leftarrow []$, $up_i.brand_i \leftarrow []$;
2. $up_i.click_i \leftarrow \text{weight}(u_i, \text{Click})$,
 $\text{normalize}(up_i.click_i)$;
3. $up_i.order_i \leftarrow \text{weight}(u_i, \text{Order})$,
 $\text{normalize}(up_i.order_i)$;
4. $up_i.follow_i \leftarrow \text{weight}(u_i, \text{Follow})$,
 $\text{normalize}(up_i.follow_i)$;
5. $up_i.cart_i \leftarrow \text{weight}(u_i, \text{Cart})$,
 $\text{normalize}(up_i.cart_i)$;
6. return UserProfile.

算法 2：画像点击日志的关键词权重衰减和归一化算法

输入： u_i , $\text{Click} = \{\text{click}_1, \text{click}_2, \dots, \text{click}_n\}$,

$\text{click}_j = \langle u_j, s_j, ct_j, cate_j, pword_j, brand_j \rangle$;

输出： $up_i.click_i = \langle u_i, Cate_i, Pword_i, Brand_i \rangle$,

$Cate_i = \{cate_1 : cw_1, cate_2 : cw_2, \dots, cate_n : cw_n\}$,

$Pword_i = \{pword_1 : pw_1, pword_2 : pw_2, \dots, pword_n : pw_n\}$,

$Brand_i = \{brand_1 : bw_1, brand_2 : bw_2, \dots, brand_n : bw_n\}$.

1. for click_j in Click:
2. if $\text{click}_j.u_i = u_i$:
3. $w_j = e^{-(\text{current_time} - \text{click}_j.ct_j) / (86\ 400\ 000 \times 90)}$;
4. if $up_i.click_i.Cate_i$ contains $\text{click}_j.cate_j$:
 - $up_i.click_i.cw_i += w_j$,
 - else
 - $up_i.click_i.cw_i = w_j$;
5. if $up_i.click_i.Pword_i$ contains $\text{click}_j.pword_j$:
 - $up_i.click_i.pw_i += w_j$,
 - else
 - $up_i.click_i.pw_i = w_j$;
6. if $up_i.click_i.Brand_i$ contains $\text{click}_j.brand_j$:
 - $up_i.click_i.bw_i += w_j$,
 - else
 - $up_i.click_i.bw_i = w_j$;
7. for $cate_j$ in $up_j.Cate_i$:
 - $up_i.click_i.cate_j.cw_j = cate_j.cw_j / \sum_{k=1}^n cate_j.cw_k$;
8. for $pword_j$ in $up_j.Pword_i$:

$$\text{up}_i.\text{click}_i.\text{pword}_j.\text{pw}_j = \text{pword}_j.\text{pw}_j / \sum_1^n \text{cate}_j.\text{cw}_k;$$

9. for brand_j in up_j.Brand_i:

$$\text{up}_i.\text{click}_i.\text{brand}_j.\text{bw}_j = \text{brand}_j.\text{bw}_j / \sum_1^n \text{brand}_j.\text{bw}_k;$$

10. return up_i.click_i.

算法 2 表达了点击维度的用户画像的描述词权重衰减和归一化算法。对应算法 1 中的 weight 和 normalize 方法（weight 为权重衰减算法、normalize 为归一化算法）。步骤 3 为权重衰减算法，根据画像构建时间点与用户操作时间点的差值可知，其值越大权重越接近于 0。步骤 4~6 分别为分类、产品词和品牌关键词的权重计算过程，对应上文的 weight 方法。步骤 7~9 分别为分类、产品词的权重归一化过程，对应上文的 normalize 方法。步骤 10 为用户点击维度的用户画像计算完毕，返回结果。用户的收藏、加购物车和购买维度的用户画像构建类似。

3 商品推荐算法

在推荐算法中，首先有用户的集合 $U = \{u_1, u_2, \dots, u_n\}$ ，商品集合 $S = \{s_1, s_2, \dots, s_m\}$ 。给定一个用户 $u_i \in U$ ，和召回商品集合 $S' = \{s_1, s_2, \dots, s_M\}$ ， $S' \in S$ 。根据分数预测模型为召回商品集合 S' 进行打分并排序，排序结果返回给用户 u_i 便完成一次推荐。下面介绍推荐算法流程（如算法 3 所示）。

算法 3：商品推荐算法

输入： $U = \{u_1, u_2, \dots, u_n\}$ ， $S = \{s_1, s_2, \dots, s_m\}$ ，
 $U' = \{u'_1, u'_2, \dots, u'_a\}$ ， $S' = \{s_1, s_2, \dots, s_M\}$ ；

输出： $\text{RankedList} = \{r_1, r_2, \dots, r_n\}$ ， $r = \{u_1, < s_1, s_2, \dots, s_b >\}$ 。

1. Label \leftarrow getLabel(U, S);
2. UserProfile \leftarrow getUserProfile(U);
3. SkuProfile \leftarrow getSkuProfile(S);
4. Feature \leftarrow getFeature(U, S, Label);
5. ScoreModel \leftarrow getScoreModel(Feature);
6. RankedList \leftarrow rankSkuList($U', S', \text{UserProfile}, \text{SkuProfile}, \text{ScoreModel}$);
7. return RankedList.

算法 3 描述了商品推荐的流程。步骤 1，构建用户标签。标签数据是标识用户对商品的操作信息的数据。在获取标签过程中需要浏览信息、点击信息和购买信息的介入。需要根据算法的优化目标对标签采取不同的处理方式，具体为根据点击率（click through rate, CTR）优化目标和转化率（click value rate, CVR）优化目标的两种标签定义方式。步骤 2，构建用户画像。根据用户画像数据，需要统计用户的点击、收藏、加购物车、购买 4 种操作所对应的商品属性词。属性词分为品牌关键词、产品词和分类词 3 种类型，需要点击、收藏、加购物车和购买 4 类信息的介入。步骤 3，构建商品画像。商品画像数据，需要商品近七日的销量、浏览量、转化率等信息来描述商品的状态。步骤 4，构建特征数据。将步骤 1 的标签数据、步骤 2 的用户画像和步骤 3 的商品画像数据结合，并根据特征重要性选择算法来挑选重要的且更为模型贡献效果的特征数据。步骤 5，分数预测模型。定义训练目标，使用回归数模型训练需要的评分模型。步骤 6，召回商品集合排序。把准备好的排序列表取得相应数据构建成特征数据输入到步

骤 5 中, 分出预测模型并产生商品评分列表, 将评分列表按照分数从高到低排序并返回即为推荐结果。步骤 7, 返回已排序的商品列表。

4 实验

4.1 数据集与实验步骤

某 B2C 电商平台 30 天的数据中约有 20 亿条用户操作数据。按照上述标准依次建立用户画像和商品画像, 然后定义用户标签, 以转化率为标准确定优化目标, 然后生成训练集表。利用所得结果的评分对结果进行排序, 实现排序推荐。在得到排序结果后进行在线评测。

4.2 在线评测指标

4.2.1 CTR

$CTR = Click/PV$ (点击数量/页面浏览量), 通常体现出该页面的吸引程度。CTR 是互联网公司的通用指标, 是互联网广告的常用术语, 指网络广告的点击达到率, 由于栏目在 app 中属于比较置顶的位置, 每天点击数巨大, 因此基于 CTR 优化模型, 也可以使频道提供更多可供用户浏览的指定商品, 从而培养用户对于特定商品的潜意识, 对形成潜在购买也有帮助。

4.2.2 CVR

$CVR = Order/Click$ (购买数量/点击数量), 为点击带来的订单率 (即点击转化率), 是电商行业的核心指标。电商公司一般都有自己搭建的平台, 但是由于页面大小的限制并不会接受第三方公司的广告需求, 因此顾客形成购买才是电商公司的核心需求。RCVR 表示浏览转化率, 即 $Order/PV$ (购买数量/页面浏览量)。转化率是电商公司的核心根本, 也就是商家商品的购买率, 因此这个指标是最核心的指标。

4.3 实验结果对比

根据对 4 月 1 日至 4 月 15 日半个月的数据观察可知, 频道有大量的流量访问, 日均 PV 为 60 万~90 万人, 日均访客量为 40 万~50 万人, 电商公司商品楼层排序推荐的近一周在线测评数据显示, 各项指标均达到了比较优异的稳定提升。如图 2 所示, 有个性化算法的 CTR 指标较人工排序提升稳定, 经计算 15 天平均提升率为 15.6%。如图 3 所示, 有个性化算法的 CVR 指标较人工排序提升稳定, 经计算 15 天平均提升率为 46.9%。图 2 和图 3 中, hu 前缀的分组数据代表无用户画像的非个性化排序, bi 前缀的分组数据代表有用户画像的非个性化排序。




图 2 CTR 结果对比

Fig. 2 Results comparison of CTR




图3 CVR 结果对比

Fig. 3 Results comparison of CVR

5 结论与展望

用户画像是广告领域、电子商务领域在识别和存储用户习惯方面的重要突破之一。梯度下降决策树模型是现今电商领域运用成熟的模型，本文在真实的电商数据基于特定业务板块需求的基础上，设定有针对性的用户画像，再根据实际的业务需求构建回归模型预测用户购买具体商品的可能性，并对其结论进行评价。实验结果表明，在使用用户画像所构建的特征和在基于梯度提升决策树的商品推荐中，CTR 和 CVR 均较人工排序的效果好。

在未来的工作中可以增加用户画像的描述力度，例如增加描述词的向量化、特征的描述力度等；也可以在回归模型上做出改进，例如应用深度学习等最新的机器学习技术。

[参考文献] (References)

- [1] 黄震华, 张佳雯, 田春岐, 等. 基于排序学习的推荐算法研究综述[J]. 软件学报, 2016, 27 (3): 691-713.
HUANG Z H, ZHANG J W, TIAN C Q, et al. Survey on learning-to-rank based recommendation algorithms[J]. Journal of Software, 2016, 27(3): 691-713. (in Chinese)
- [2] XU H S, ZHANG R L, LIN C J, et al. Construction of E-commerce recommendation system based on semantic annotation of ontology and user preference[J]. Indonesian Journal of Electrical Engineering and Computer Science, 2014, 12(3): 2028-2035.
- [3] GUPTA Y, SAINI A, SAXENA A K. A new fuzzy logic based ranking function for efficient information retrieval system[J]. Expert Systems with Applications, 2015, 42(3): 1223-1234.
- [4] COLOMBO-MENDOZA L O, VALENCIA-GARCÍA R, RODRÍGUEZ-GONZÁLEZ A, et al. RecomMetz: a context-aware knowledge based mobile recommender system for movie show times[J]. Expert Systems with Applications, 2015, 42(3): 1202-1222.
- [5] 郝胜宇, 陈静仁. 大数据时代用户画像助力企业实现精准化营销[J]. 中国集体经济, 2016 (4): 61-62.
HAO S Y, CHEN J R. User's portrait assisted enterprises achieving precision marketing in the big data era[J]. China Collective Economy, 2016(4): 61-62. (in Chinese)
- [6] ADOMAVICIUS G, TUZHILIN A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions[J]. IEEE Transaction on Knowledge and Data Engineering, 2005, 17(6): 734-749.
- [7] FUHR N. Optimum polynomial retrieval functions based on the probability ranking principle[J]. ACM Transactions on Information Systems (TOIS), 1989, 7(3): 183-204.
- [8] CAO Y B, XU J, LIU T Y, et al. Adapting Ranking SVM to document retrieval[C]//Proceedings of the 29th Annual

-
- International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2006: 186-193.
- [9] CAO H W, VERMA R, NENKOVA A. Speaker-sensitive emotion recognition via ranking: studies on acted and spontaneous speech[J]. Computer Speech & Language, 2015, 29(1): 186-202.
- [10] SONG Y, WANG H N, HE X D. Adapting deep RankNet for personalized search[C]//WSDM'14 Proceedings of the 7th ACM International Conference on Web Search and Data Mining. New York: ACM, 2014: 83-92.
- [11] FREUND Y, IYER R, SCHAPIRE R E, et al. An efficient boosting algorithm for combining preferences[J]. Journal of Machine Learning Research, 2003, 4: 933-969.
- [12] KOREN Y, BELL R, VOLINSKY C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.